Université de Toulouse

Football : Qui va gagner ?

PROJET
D'INTELLIGENCE ARTIFICIELLE

HAMOUDI MALAK MELISSA

FONTANIE MATHIS ERWAN

Objectifs du projet

1 - Segmenter les joueurs en profils types grâce au clustering non supervisé

2 - Prédire l’issue d’un match (victoire / nul / défaite) à partir des statistiques des équipes

Préparation des données joueurs

- Données = statistiques de joueurs par match (passes, tirs, fautes…)
- Fusion des fichiers home / away
- Nettoyage : suppression des colonnes inutiles, NaN > 40 %, faible variance
- Standardisation des valeurs (centré-réduit)
- Réduction de dimension par PCA (3 composantes principales)

Clustering des joueurs (KMeans, k=4)

- Méthode : KMeans après réduction PCA
- Choix de k = 4 selon score silhouette (voir graphe)

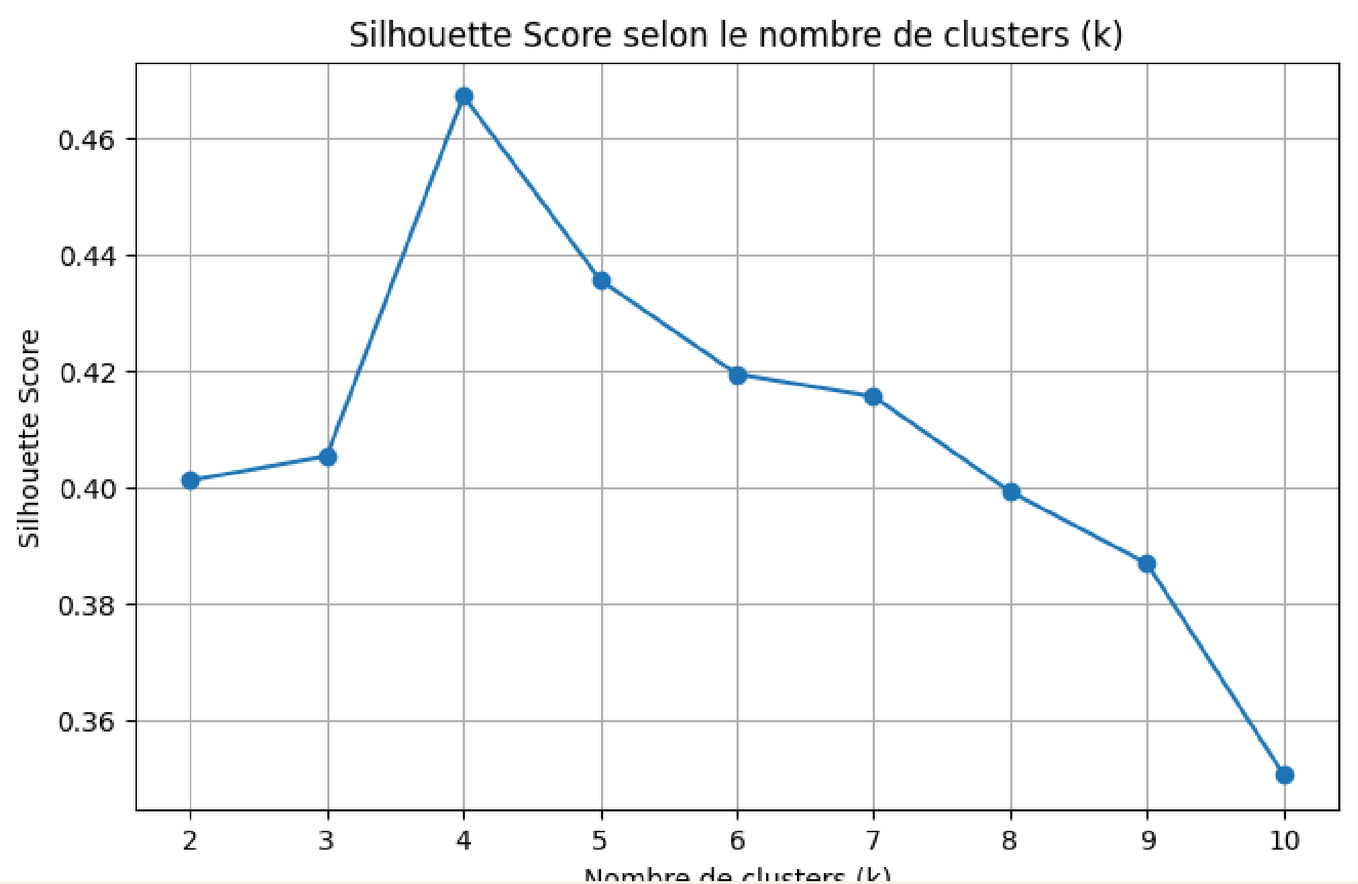

Clustering des joueurs (KMeans, k=4)

- 4 groupes bien séparés dans l'espace PCA

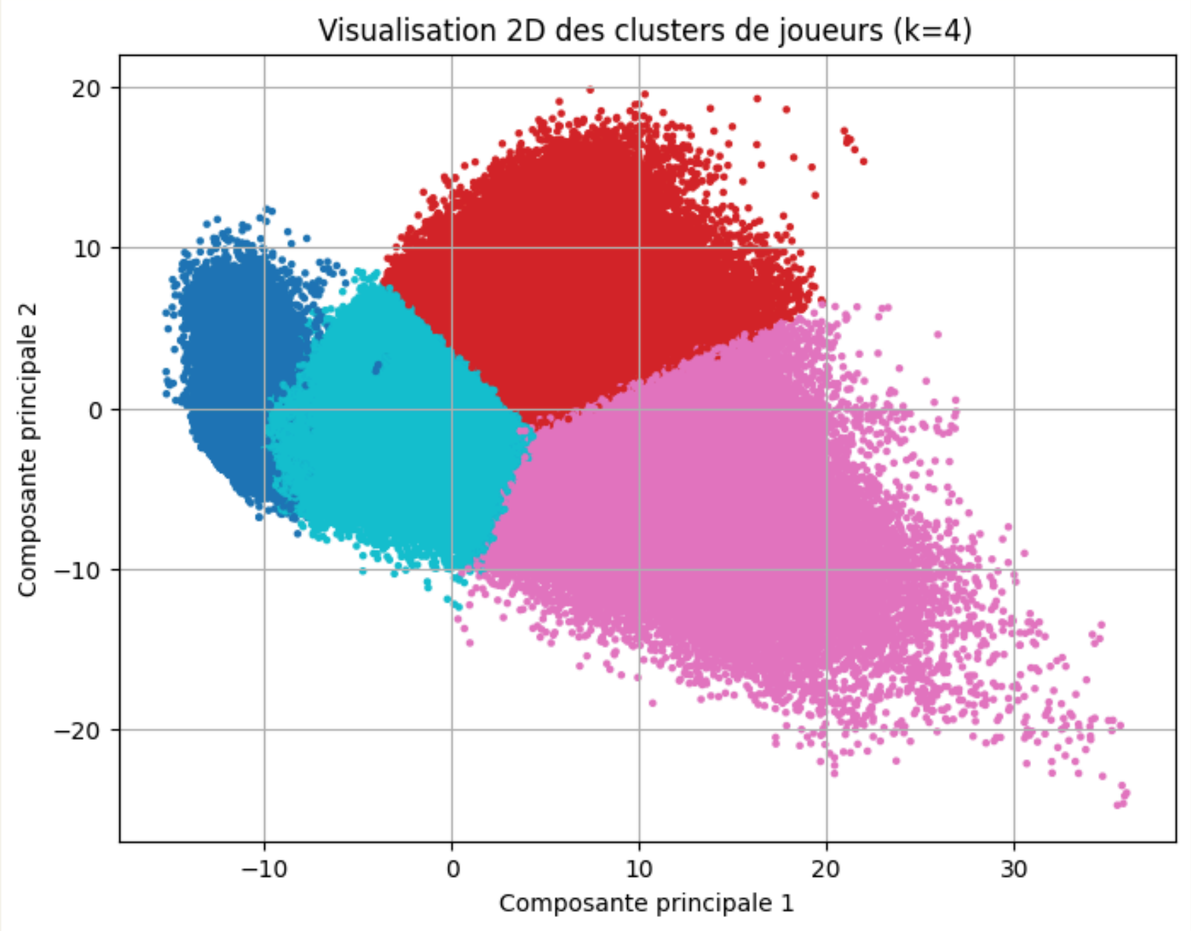

Profils types de joueurs par cluster

Cluster 0 → 77 298 joueurs
Cluster 1 → 115 167 joueurs
Cluster 2 → 87 201 joueurs
Cluster 3 → 193 545 joueurs

Cluster 0 : peu actifs/remplaçant
Cluster 1 : très défensifs (dégagements, tacles)
Cluster 2 : offensifs (buts, passes décisives)
Cluster 3 : joueurs polyvalents

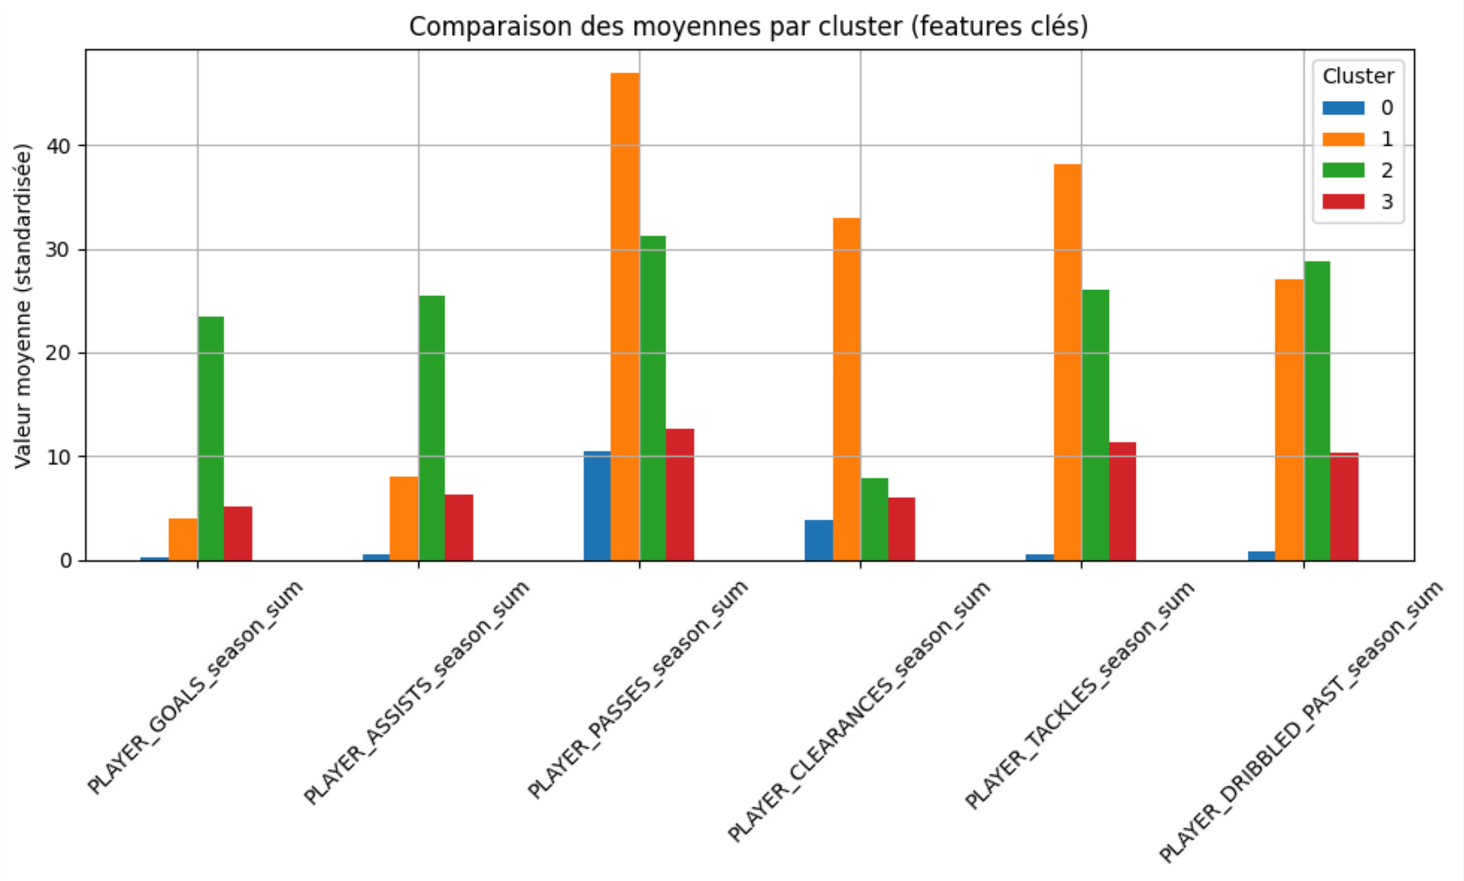

Préparation des données et modèles testés

- Fusion des features domicile / extérieur
- Suppression colonnes non numériques
- Imputation des NaN, standardisation

- Modèles utilisés :

1. Arbre de Décision
2. Random Forest
3. Random Forest + GridSearchCV

Comparaison des modèles

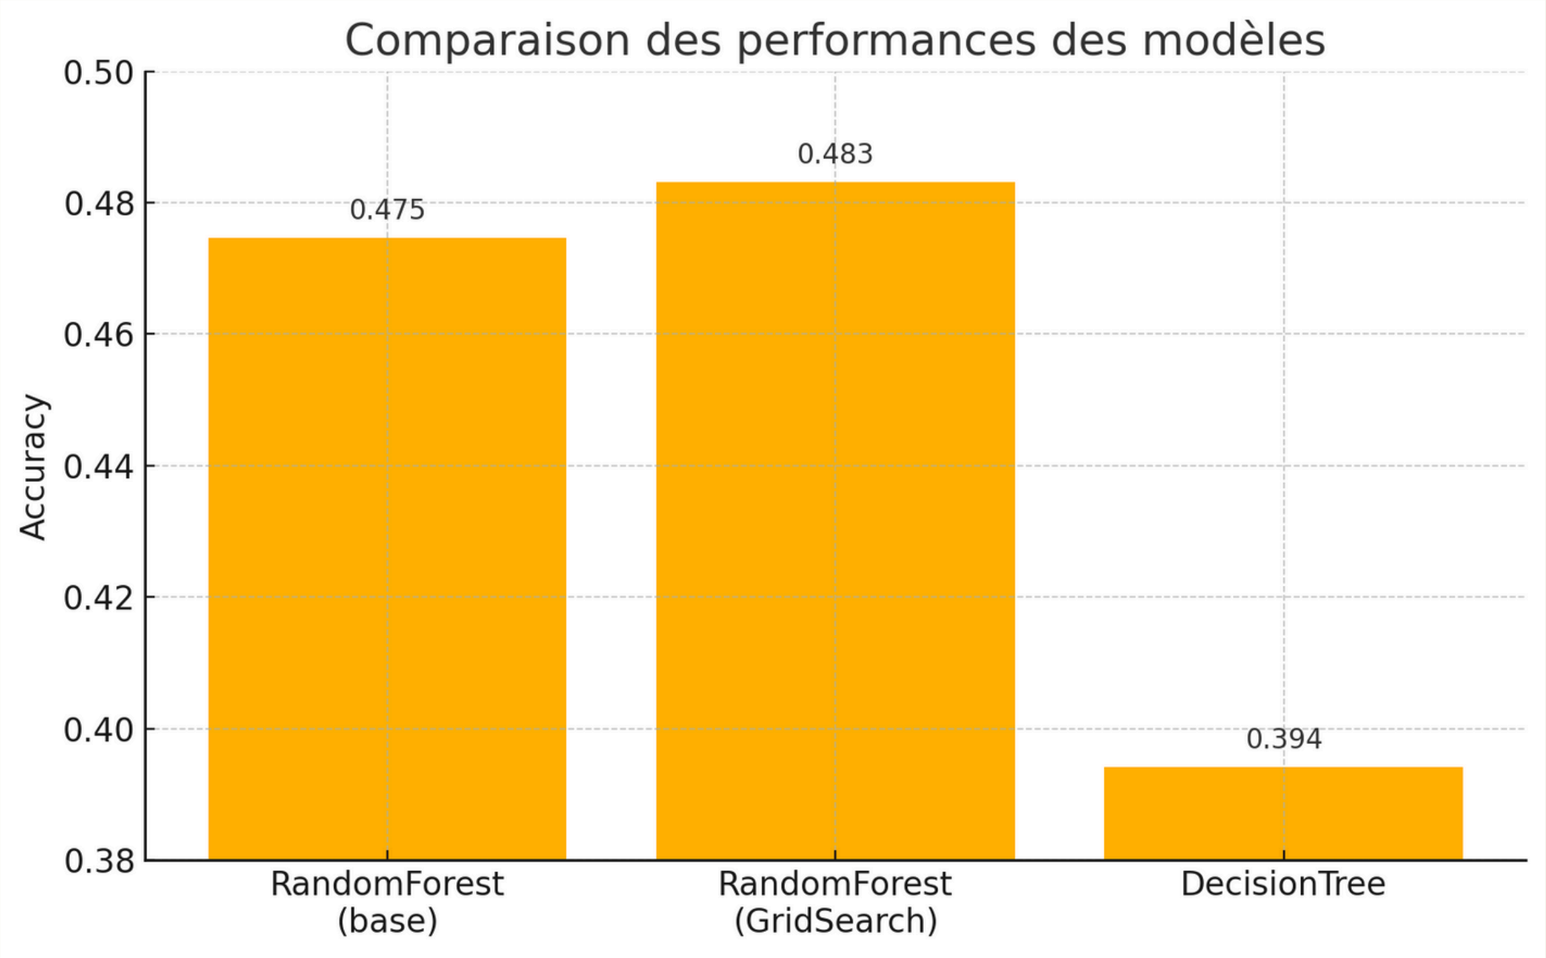

Matrices de Confusion

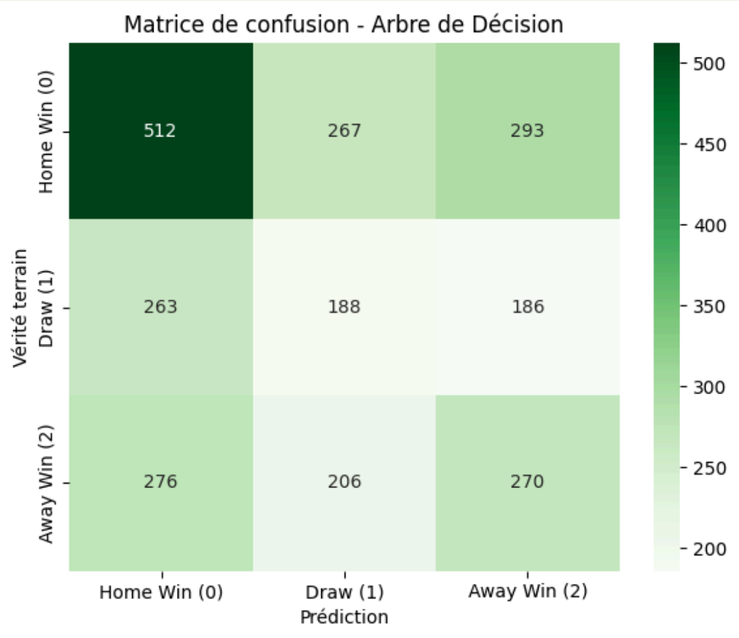

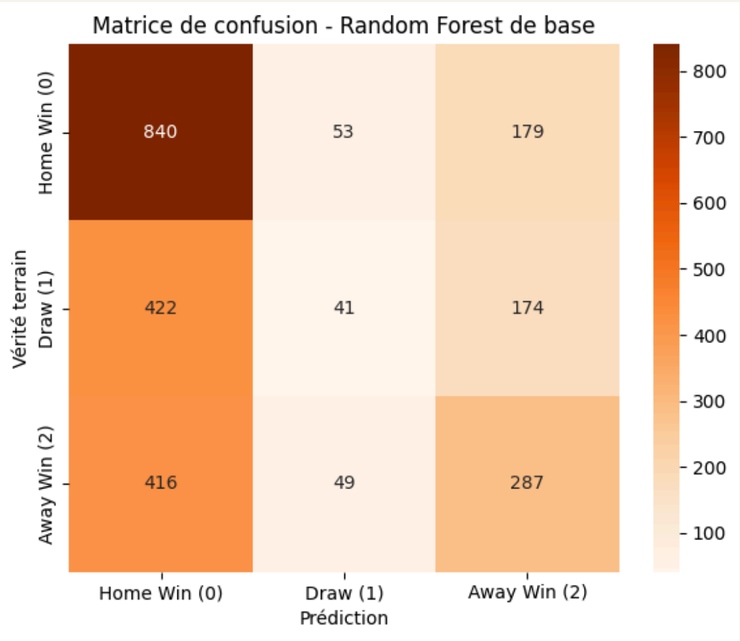

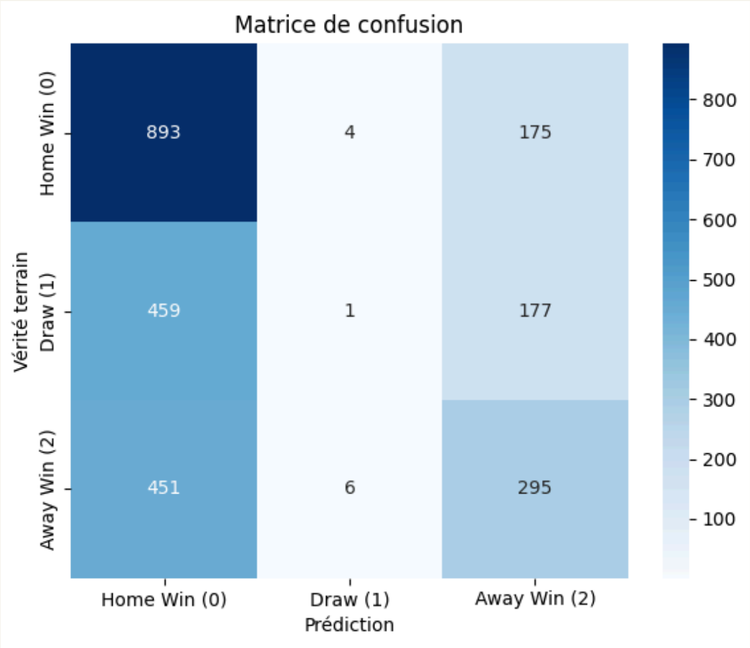

Export final de la prédiction

- Prédiction prête pour chaque match dans y_pred_final.csv
- Projet complet : data → modèle → prédiction → export
- Modèle prêt à être évalué sur la plateforme officielle

0,4850204982655314

ID	HOME_WINS	DRAW	AWAY_WINS
12303	1	0	0
12304	0	0	1
12305	1	0	0
12306	1	0	0
12307	1	0	0
12308	1	0	0
12309	1	0	0
12310	1	0	0
12311	0	0	1
12312	1	0	0
12313	0	0	1
12314	1	0	0
12315	0	0	1
12316	1	0	0
12317	1	0	0
12318	1	0	0
12319	1	0	0
12320	1	0	0
12321	1	0	0
12322	1	0	0
12323	0	0	1
12324	1	0	0
12325	1	0	0
12326	1	0	0
12327	0	0	1